

**TRABAJO 1: REDES NEURONALES ARTIFICIALES Y ALGORITMOS
BIOINSPIRADOS OPTIMIZACIÓN HEURISTICA**

Presentado por:

Jhorlan Daniel Ortega Domínguez

jhortegad@unal.edu.co

Docente:

Juan David Ospina Arango

Martes 23 de junio



Universidad Nacional de Colombia
Facultad de Minas
Ingeniería de Sistemas e Informática
2026

Nota: Para llevar un mayor orden en el trabajo se propone la siguiente pagina web:
https://jhorlan-ortega.github.io/Bio_Algoritmos.github.io/

1. Introducción

La optimización es un pilar central en la ingeniería y las ciencias computacionales. Los métodos clásicos basados en gradiente son eficaces cuando la función objetivo es diferenciable y unimodal, pero su rendimiento se deteriora ante funciones ruidosas, discontinuas o con numerosos óptimos locales. En estos casos, los algoritmos inspirados en procesos naturales como la evolución, el comportamiento de enjambres o la búsqueda de alimento de colonias de hormigas, ofrecen alternativas robustas y flexibles (Dorigo & Stützle, 2004). En este trabajo se exploran seis funciones de referencia que cubren diferentes tipos de dificultad, y se aplican métodos de optimización global para evaluar su desempeño.

2. Ejercicio 1: Optimización Numérica

2.1 Función de Rosenbrock

Definida por la expresión:

$$\sum_{i=1}^{n-1} [100 * (x_{i+1} - x_i^2)^2 + (1 - x_i)^2]$$

Su mínimo global es cero. El reto computacional radica en que el mínimo se encuentra al fondo de una valle estrecho y curvilíneo, lo que dificulta la convergencia de métodos de primero orden.




Figura1. Tomado de Virtual Library of Simulation Experiments. Rosenbrock Function, 2013

2.2 Función de Rastrigin

Definida por la expresión:

$$10 * n + \sum_{i=1}^n [x_i^2 - 10 * \cos(2\pi x_i)]$$

Definida como:

Con mínimo global cero y dominio $x_i \in [-5.12, 5.12]$. Su gran número de mínimos locales la convierte en una prueba exigente para cualquier algoritmo de búsqueda.




Figura2. Tomado de Virtual Library of Simulation Experiments. Rastrigin Function, 2013

2.3 Función Schwefel

Definida por la expresión:

$$418.9829 * n - \sum_{i=1}^n [x_i * \sin(\sqrt{|x_i|})]$$

Con mínimo global cero en el punto (420.9687, 420.9687) y dominio $x_i \in [-500, 500]$. Presenta un fuerte efecto de engaño, ya que el mínimo global se encuentra muy alejado de los mínimos locales, lo que obliga a los

optimizadores a mantener una alta diversidad poblacional para no converger prematuramente.




Figura3. Tomado de Virtual Library of Simulation Experiments. Schwefel Function, 2013

2.4 Función Griewank

Definida por la expresión:

$$1 + \frac{1}{4000} \sum_{i=1}^n [x_i^2 * - \prod_{i=1}^n \cos(\frac{x_i}{\sqrt{i}})]$$

Con mínimo global cero en el origen y dominio $x_i \in [-600, 600]$. Su estructura combina un componente cuadrático con un producto de cosenos, generando una distribución regular de mínimos locales, pero con un valle central profundo que facilita la convergencia una vez que se identifica la región a tractora.




Figura4. Tomado de Virtual Library of Simulation Experiments. Griewank Function, 2013

2.5 Función Goldstein-Price

Definida por la expresión:

$$[1 + (x + y + 1)^2 * (19 - 14x + 3x^2 - 14y + xy + 3y^2)] * [30 + (2x - 3y)^2 * (18 - 32x + 12x^2 + 48y - 36xy + 27y^2)]$$

Con mínimo global en $(0, -1)$ cuyo valor es 3 y dominio $x, y \in [-2, 2]$. Es una función multimodal con un mínimo global muy profundo y rodeado de múltiples óptimos locales.




Figura5. Tomado de Virtual Library of Simulation Experiments. Goldstein-Price Function, 2013

2.6 Función Seis Jorobas de Camello

Definida por la expresión:

$$\left(4 - 2.1x^2 + \frac{x^4}{3}\right) * x^2 + xy + (-4 + 4y^2) * y^2$$

Con dos mínimos globales simétricos en $(\pm 0.0898, \mp 0.7126)$ de valor -1.0316 , y dominio $x \in [-3, 3]$, $y \in [-2, 2]$. Presenta seis mínimos locales en total, pero solo dos globales, lo que exige a los optimizadores una exploración suficiente para identificar cualquiera de los dos valles profundos sin quedarse en los otros cuatro mínimos.




Figura6. Tomado de *Virtual Library of Simulation Experiments. Six-Hump Camel Function*, 2013

En este primer punto se abordó la optimización de las funciones antes mencionadas, tanto en dos como en tres dimensiones, empleando el método de descenso por gradiente. Para el punto de partida del algoritmo, se utilizó una condición inicial aleatoria muestreada a partir de una distribución uniforme en el intervalo $[-2, 2]$; esta elección responde a que dicho rango es el dominio estándar en el que se evalúan estas funciones de prueba, ya que contiene sus mínimos globales y las zonas de mayor relevancia topográfica, lo que permite un punto de partida homogéneo y comparable entre todas las funciones evaluadas.

El proceso se repitió con un número de iteraciones $n = 100, 500, 1000$ y 20000 . El valor más alto se justifica por la tasa de aprendizaje fijada en 0.001 , la cual produce actualizaciones muy pequeñas en cada paso; al ser el descenso tan gradual, se requieren esas 20000 iteraciones para poder apreciar de manera clara la trayectoria completa y la convergencia final del algoritmo.

Con el fin de optimizar la implementación y evitar redundancias, se generó una función general en el código que recibe como parámetro la función de prueba en 2D (definida mediante la librería Symbol de SymPy) y el número de iteraciones y la semilla aleatoria. De igual manera, se desarrolló una función análoga para el caso tridimensional, lo que permitió reutilizar eficientemente el código para todas las configuraciones planteadas. En cuanto a la representación gráfica, los histogramas (que muestran la trayectoria de descenso) se presentan únicamente para las funciones de 2D, donde las dos variables independientes son x e y . Para las funciones en 3D, si bien se realizó el cálculo de la optimización, se optó por no generar estas visualizaciones debido a la dificultad de representar una cuarta dimensión (las tres variables independientes más el valor de la función objetivo) en un gráfico convencional.

Finalmente, el número total de evaluaciones de la función objetivo, equivalente al número de iteraciones ejecutadas, se encuentra indicado en el título de cada uno de los histogramas bidimensionales mostrados.

A continuación, se presenta los histogramas de cada una de las funciones de Prueba con 20.000 iteraciones.

Camino decreciente sobre la superficie de Rosenbrock con 20.000 iteraciones:

Función Rosenbrock:




Figura7 Camino decreciente sobre la superficie de Rosenbrock con 20.000 iteraciones

Función Rastrigin:




Figura8 Camino decreciente sobre la superficie de Rastrigin con 20.000 iteraciones

Función Schwefel:




Figura9 Camino decreciente sobre la superficie de Rastrigin con 20.000 iteraciones

Función Griewank:




Figura10 Camino decreciente sobre la superficie de Rastrigin con 20.000 iteraciones

Función Goldstein-Price




Figura11 Camino decreciente sobre la superficie de Goldstein-Price con 20.000 iteraciones

Función Camello

Seis Jorobas de




Figura12 Camino decreciente sobre la superficie de Rastrigin con 20.000 iteraciones

Una vez aplicado el enfoque basado en el descenso por gradiente, que es un método determinista que requiere diferenciabilidad y que tiende a quedar atrapado en mínimos locales debido a su naturaleza de búsqueda secuencial, se procedió a optimizar las seis funciones de prueba (Rosenbrock, Rastrigin, Schwefel, Griewank, Goldstein-Price y Seis jorobas de camello) en su formulación bidimensional empleando dos metaheurísticas poblacionales pertenecientes a la familia de los algoritmos evolutivos.

La principal ventaja de los algoritmos evolutivos radica en que no exigen que la función objetivo sea continua ni diferenciable, ya que no calculan derivadas para guiar la búsqueda. Esto los convierte en optimizadores de caja negra capaces de abordar problemas donde el gradiente no existe, es ruidoso o resulta extremadamente costoso de obtener. Además, al trabajar con una población de soluciones simultáneamente en lugar de un único punto, estos algoritmos exploran diversas regiones del espacio de búsqueda en paralelo.

Esta característica les confiere una notable capacidad para escapar de los óptimos locales. Por tanto, mientras que el gradiente es excelente para refinamientos locales, los algoritmos evolutivos son la opción preferida cuando se desea una exploración global robusta.

Para materializar esta etapa del estudio, se hizo uso del módulo evolutivo proporcionado en clase, cuyo código fuente implementa las funciones fundamentales para representar una población inicial, una operación de mutación, cruzamiento, siguiente generación y la evaluación de la población con la función objetivo.

Función Rosenbrock:




Figura13 Grafica el valor de la función objetivo con la mejor solución calculada en cada generación

Función Rastrigin:




Figura14 Grafica el valor de la función objetivo con la mejor solución calculada en cada generación

Función Schwefel:




Figura15 Grafica el valor de la función objetivo con la mejor solución calculada en cada generación

Función Griewank:




Figura15 Grafica el valor de la función objetivo con la mejor solución calculada en cada generación

Función Goldstein-Price:




Figura16 Grafica el valor de la función objetivo con la mejor solución calculada en cada generación

Función Seis Jorobas de Camello:




Figura16 Grafica el valor de la función objetivo con la mejor solución calculada en cada generación

Por su parte, el PSO está inspirado en el comportamiento social de bandadas de aves o bancos de peces cuando se desplazan en busca de alimento. En este modelo, cada partícula representa una solución candidata que "vuela" por el espacio de búsqueda ajustando su trayectoria en función de dos referentes: su propia mejor posición histórica (mejor personal) y la mejor posición alcanzada por cualquier partícula del enjambre (mejor global). Este mecanismo dota al algoritmo de un equilibrio dinámico entre exploración (cuando las partículas se dispersan para recorrer nuevas zonas) y explotación (cuando se agrupan en torno al mejor hallazgo para refinarlo). La relevancia del PSO en el ámbito de la optimización continua radica en su extrema simplicidad conceptual, su facilidad de implementación, el reducido número de parámetros que requiere ajustar y su probada eficacia en una amplia variedad de problemas, lo que lo ha consolidado como una de las metaheurísticas más populares y versátiles de la actualidad.

Función Rosenbrock:




Figura17 Optimización de la función Rosenbrock con Optimización de Partículas

Función Rastrigin:




Figura18 Optimización de la función Rastrigin con Optimización de Partículas

Función Schwefel:




Figura19 Optimización de la función Schwefel con Optimización de Partículas

Función Griewank:




Figura20 Optimización de la función Griewank con Optimización de Partículas

Función Goldstein




Figura21 Optimización de la función Goldstein con Optimización de Partículas

Función Seis Jorobas de Camello:




Figura22 Optimización de la función Seis Jorobas de Camello con Optimización de Partículas

Para complementar el análisis, se incluye una animación en formato GIF que representa el proceso de convergencia del algoritmo PSO aplicado a la función de Rosenbrock. En ella se aprecia cómo el enjambre de partículas explora el espacio de búsqueda y converge hacia el mínimo global. El archivo multimedia está alojado en la plataforma web y su visualización se activa mediante el botón 'GIF'.

3. Ejercicio 2: Optimización Combinatoria

Se abordó el problema de optimización de rutas para un vendedor que debe recorrer las 96 capitales departamentales de Francia. La función de costo total se definió como la suma ponderada de tres factores: el valor económico del tiempo invertido por el vendedor, el coste acumulado de los peajes en las autopistas y carreteras seleccionadas, y el gasto en combustible, que depende de la distancia y del rendimiento del vehículo.

La naturaleza combinatoria del problema hace inviable un enfoque de fuerza bruta. Por ello, se implementó un algoritmo genético, cuyas ventajas radican en su capacidad para manejar espacios de búsqueda discretos y multimodalidades, su robustez frente a óptimos locales y su eficiencia computacional en problemas de gran escala.




Figura23 Grafico de visualización de la mejor solución




Figura24 Grafico de Recorrido resultante con la mejor solución

4. Uso de la IA

Los prompts utilizados durante el desarrollo del trabajo tuvieron como propósito facilitar la comprensión del funcionamiento de los algoritmos, así como para la depuración del código a la hora de utilizar librerías nuevas.

Algunos de los prompts más importantes fueron:

- ¿Cómo funciona la Optimización por Enjambre de Partículas?
- ¿Cómo funciona el algoritmo de Colonias de Hormigas para resolver el Problema del Vendedor Viajero?
- ¿Cómo creo un GIF animado en Python con matplotlib?

En cuanto al impacto de la inteligencia artificial, este fue positivo, ya que permitió obtener un material más claro y comprensible, lo que contribuyó a una mejor asimilación de los conceptos trabajados y a una presentación más accesible de los resultados.

5. Conclusiones

- El descenso por gradiente demostró ser una herramienta eficaz para funciones diferenciables y unimodales, como se observó en la convergencia hacia el mínimo global de Rosenbrock y Griewank cuando la tasa de aprendizaje y el número de iteraciones fueron adecuados. Sin embargo, su rendimiento se vio fuertemente limitado en funciones altamente multimodales como Rastrigin y Schwefel, donde la sensibilidad a la condición inicial y la naturaleza secuencial del método provocaron frecuentes estancamientos en mínimos locales, incluso con 20 000 iteraciones.
- Los algoritmos evolutivos como genético, PSO y colonia de hormigas superaron ampliamente al gradiente en la exploración global del espacio de búsqueda. Su capacidad para mantener múltiples soluciones simultáneamente y para operar sin requerir diferenciabilidad les permitió escapar de óptimos locales y encontrar soluciones de alta calidad en todas las funciones de prueba, incluidas aquellas con grandes extensiones de mínimos locales y valles estrechos.
- La elección del método de optimización debe alinearse con la naturaleza del problema. Mientras que el gradiente es insuperable para refinamientos locales y problemas convexos, los algoritmos Bioinspirados son la opción recomendada cuando la función es multimodal, ruidosa, discontinua o cuando no se dispone de información analítica del gradiente. Esta complementariedad quedó patente al comparar los resultados de ambos enfoques sobre el mismo conjunto de funciones.
- En el problema del viajante con 96 capitales francesas, el algoritmo genético demostró ser una estrategia práctica y eficiente para obtener rutas de bajo costo, integrando de manera realista factores económicos como tiempo de viaje, peajes y combustible. La naturaleza combinatoria del problema hace inviable cualquier método exacto, validando así el uso de metaheurísticas poblacionales para problemas de gran escala.

5. Referencias

Applegate, D. L., Bixby, R. E., Chvátal, V., & Cook, W. J. (2006). The traveling salesman problem: A computational study. Princeton University Press

Dorigo, M., & Stützle, T. (2004). Ant colony optimization. MIT Press.
<https://doi.org/10.7551/mitpress/1290.001.0001>.